

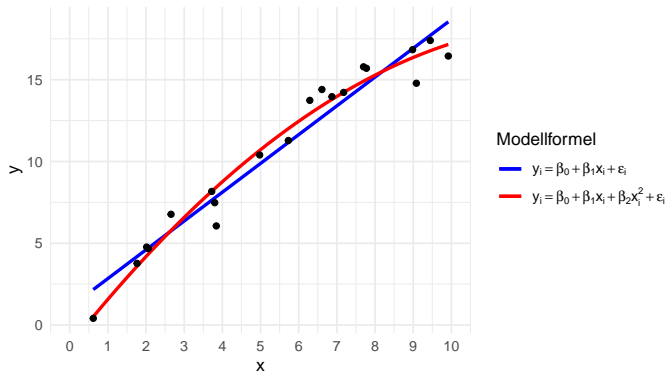
Was soll der Ramsey RESET Test prüfen?

**Regression Equation Specification Error Test** von James **Ramsey** (1969)

# Was soll der Ramsey RESET Test prüfen?

**Regression Equation Specification Error Test** von James **Ramsey** (1969)

*Ist die Modellgleichung im Regressionsmodell fehlspezifiziert?*



## Welches Modell ist richtig?

Wir können das quadratische Modell schätzen und mit dem t-Test überprüfen, ob  $\beta_2$  signifikant (von Null verschieden) ist:

```
formula <- y ~ x + I(x^2)
quadratic_model <- lm(formula, data)
```

## Welches Modell ist richtig?

Wir können das quadratische Modell schätzen und mit dem t-Test überprüfen, ob  $\beta_2$  signifikant (von Null verschieden) ist:

```
formula <- y ~ x + I(x^2)
quadratic_model <- lm(formula, data)
```

```
summary(quadratic_model)$coefficients
```

##	Estimate	Std. Error	t value	Pr(> t )
## (Intercept)	-1.27	0.816	-1.6	0.13864997
## x	2.95	0.345	8.5	0.00000015
## I(x^2)	-0.11	0.031	-3.5	0.00258782

## Welches Modell ist richtig?

Wir können das quadratische Modell schätzen und mit dem t-Test überprüfen, ob  $\beta_2$  signifikant (von Null verschieden) ist:

```
formula <- y ~ x + I(x^2)
quadratic_model <- lm(formula, data)
```

```
summary(quadratic_model)$coefficients
```

##	Estimate	Std. Error	t value	Pr(> t )
## (Intercept)	-1.27	0.816	-1.6	0.13864997
## x	2.95	0.345	8.5	0.00000015
## I(x^2)	-0.11	0.031	-3.5	0.00258782

Hier ist der p-value für  $H_0 : \beta_2 = 0$  ziemlich klein, also wird  $H_0$  verworfen. Wir würden uns also für das quadratische Modell entscheiden.

# Funktioniert dieses Vorgehen auch bei mehreren Regressoren?

Bei  $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$  gegen  $y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \epsilon_i$  hat das gut funktioniert.

Und wenn wir mehr als nur einen Regressor haben?

## Funktioniert dieses Vorgehen auch bei mehreren Regressoren?

Bei  $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$  gegen  $y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \epsilon_i$  hat das gut funktioniert.

Und wenn wir mehr als nur einen Regressor haben?

$$\text{Hauspreis}_i = \beta_0 + \beta_1 \text{Wohnfläche}_i + \beta_2 \text{Schlafzimmeranzahl}_i + \beta_3 \text{Baujahr}_i + \epsilon_i$$

## Funktioniert dieses Vorgehen auch bei mehreren Regressoren?

Bei  $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$  gegen  $y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \epsilon_i$  hat das gut funktioniert.

Und wenn wir mehr als nur einen Regressor haben?

$$\text{Hauspreis}_i = \beta_0 + \beta_1 \text{Wohnfläche}_i + \beta_2 \text{Schlafzimmeranzahl}_i + \beta_3 \text{Baujahr}_i + \epsilon_i$$

Hier gibt es viel mehr Möglichkeiten:

- Quadratische Terme:  $\text{Wohnfläche}_i^2$ ,  $\text{Schlafzimmeranzahl}_i^2$ ,  $\text{Baujahr}_i^2$
- Interaktionsterme:  $\text{Wohnfläche}_i \cdot \text{Schlafzimmeranzahl}_i$ , ...
- Kubische Terme:  $\text{Wohnfläche}_i^3$ , ...

Für jede Möglichkeit einen t-Test durchzuführen ist zu aufwendig.



# Was ist nun Ramsey's Idee?

1 Schätze das Ausgangsmodell:

$$\text{Hauspreis}_i = \beta_0 + \beta_1 \text{Wohnfläche}_i + \beta_2 \text{Schlafzimmeranzahl}_i + \beta_3 \text{Baujahr}_i + \epsilon_i$$

# Was ist nun Ramsey's Idee?

- 1 Schätze das Ausgangsmodell:

$$\text{Hauspreis}_i = \beta_0 + \beta_1 \text{Wohnfläche}_i + \beta_2 \text{Schlafzimmeranzahl}_i + \beta_3 \text{Baujahr}_i + \epsilon_i$$

- 2 Berechne die Prognosen:

$$\widehat{\text{Hauspreis}}_i = \hat{\beta}_0 + \hat{\beta}_1 \text{Wohnfläche}_i + \hat{\beta}_2 \text{Schlafzimmeranzahl}_i + \hat{\beta}_3 \text{Baujahr}_i$$

# Was ist nun Ramsey's Idee?

- 1 Schätze das Ausgangsmodell:

$$\text{Hauspreis}_i = \beta_0 + \beta_1 \text{Wohnfläche}_i + \beta_2 \text{Schlafzimmeranzahl}_i + \beta_3 \text{Baujahr}_i + \epsilon_i$$

- 2 Berechne die Prognosen:

$$\widehat{\text{Hauspreis}}_i = \hat{\beta}_0 + \hat{\beta}_1 \text{Wohnfläche}_i + \hat{\beta}_2 \text{Schlafzimmeranzahl}_i + \hat{\beta}_3 \text{Baujahr}_i$$

- 3 Schätze erneut, aber diesmal **mit Potenzen der Prognosen als Regressoren**:

$$\begin{aligned} \text{Hauspreis}_i = & \beta_0 + \beta_1 \text{Wohnfläche}_i + \beta_2 \text{Schlafzimmeranzahl}_i + \beta_3 \text{Baujahr}_i \\ & + \beta_4 \widehat{\text{Hauspreis}}_i^2 + \beta_5 \widehat{\text{Hauspreis}}_i^3 + \epsilon_i \end{aligned}$$

# Was ist nun Ramsey's Idee?

- 1 Schätze das Ausgangsmodell:

$$\text{Hauspreis}_i = \beta_0 + \beta_1 \text{Wohnfläche}_i + \beta_2 \text{Schlafzimmeranzahl}_i + \beta_3 \text{Baujahr}_i + \epsilon_i$$

- 2 Berechne die Prognosen:

$$\widehat{\text{Hauspreis}}_i = \hat{\beta}_0 + \hat{\beta}_1 \text{Wohnfläche}_i + \hat{\beta}_2 \text{Schlafzimmeranzahl}_i + \hat{\beta}_3 \text{Baujahr}_i$$

- 3 Schätze erneut, aber diesmal **mit Potenzen der Prognosen als Regressoren**:

$$\begin{aligned} \text{Hauspreis}_i = & \beta_0 + \beta_1 \text{Wohnfläche}_i + \beta_2 \text{Schlafzimmeranzahl}_i + \beta_3 \text{Baujahr}_i \\ & + \beta_4 \widehat{\text{Hauspreis}}_i^2 + \beta_5 \widehat{\text{Hauspreis}}_i^3 + \epsilon_i \end{aligned}$$

- 4 Teste  $H_0 : \beta_4 = \beta_5 = 0$  mit einem F-Test.

## Warum nicht auch die erste Potenz der Prognosen?

Die  $\widehat{\text{Hauspreis}}$  Werte sind bereits eine Linearkombination der Regressoren. Würden sie zusätzlich aufgenommen werden, würde das zu Multikollinearität führen.

## Warum nicht auch die erste Potenz der Prognosen?

Die <sup>^</sup>Hauspreis Werte sind bereits eine Linearkombination der Regressoren. Würden sie zusätzlich aufgenommen werden, würde das zu Multikollinearität führen.

## Bis zur wievielten Potenz?

Dafür gibt es keine allgemeine Regel, meistens wählt man die 2. und 3. Potenz.

## Warum nicht auch die erste Potenz der Prognosen?

Die <sup>Hauspreis</sup> Werte sind bereits eine Linearkombination der Regressoren. Würden sie zusätzlich aufgenommen werden, würde das zu Multikollinearität führen.

## Bis zur wievielten Potenz?

Dafür gibt es keine allgemeine Regel, meistens wählt man die 2. und 3. Potenz.

## Vor- und Nachteile des Verfahrens?

- 👍 Kann auch bei einer Vielzahl an Regressoren effizient angewendet werden. Wir brauchen kein Alternativmodell definieren.
- 👎 Es kann zwar aufgezeigt werden, *ob* eine Fehlspezifikation vorliegt, aber nicht *welcher Art*.