

# Lineare Regression in R

```
str(hauspreise) # Quelle: wooldridge::hprice1 (transformiert)
```

```
'data.frame':  88 obs. of  4 variables:  
 $ preis      : num  300000 370000 191000 195000 373000 ...  
 $ wohnflaeche : num  226 193 128 135 234 ...  
 $ schlafzimmer: int   4 3 3 3 4 5 3 3 3 3 ...  
 $ grundflaeche: num  569 920 483 427 566 ...
```

# Lineare Regression in R

Falls es dich interessiert, genau so habe ich den Datensatz hauspreise gebildet:

```
library(dplyr)
umrechnungsfaktor <- 0.09290304
hauspreise <- wooldridge::hprice1 %>%
  summarize(
    preis = price * 1000,
    wohnflaeche = sqrft * umrechnungsfaktor,
    schlafzimmer = bdrms,
    grundflaeche = lotsize * umrechnungsfaktor
  )
```

# Lineare Regression in R

```
str(hauspreise) # Quelle: wooldridge::hprice1 (transformiert)
```

```
'data.frame':  88 obs. of  4 variables:  
 $ preis      : num  300000 370000 191000 195000 373000 ...  
 $ wohnflaeche : num   226  193  128  135  234 ...  
 $ schlafzimmer: int    4  3  3  3  4  5  3  3  3  3 ...  
 $ grundflaeche: num   569  920  483  427  566 ...
```

# Lineare Regression in R

```
str(hauspreise) # Quelle: wooldridge::hprice1 (transformiert)
```

```
'data.frame':  88 obs. of  4 variables:  
 $ preis      : num  300000 370000 191000 195000 373000 ...  
 $ wohnflaeche : num  226 193 128 135 234 ...  
 $ schlafzimmer: int   4 3 3 3 4 5 3 3 3 3 ...  
 $ grundflaeche: num  569 920 483 427 566 ...
```

```
model <- lm(  
  formula = preis ~ wohnflaeche + I(schlafzimmer > 4) + grundflaeche,  
  data = hauspreise  
)
```

# Lineare Regression in R

```
str(hauspreise) # Quelle: wooldridge::hprice1 (transformiert)
```

```
'data.frame':  88 obs. of  4 variables:
 $ preis      : num  300000 370000 191000 195000 373000 ...
 $ wohnflaeche : num  226 193 128 135 234 ...
 $ schlafzimmer: int   4 3 3 3 4 5 3 3 3 3 ...
 $ grundflaeche: num  569 920 483 427 566 ...
```

```
model <- lm(
  formula = preis ~ wohnflaeche + I(schlafzimmer > 4) + grundflaeche,
  data = hauspreise
)
```

```
summary(model)
```

Call:

```
lm(formula = preis ~ wohnflaeche + I(schlafzimmer > 4) + grundflaeche,  
    data = hauspreise)
```

Residuals:

Min	1Q	Median	3Q	Max
-149356	-27653	-3891	24175	202625

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	5.384e+04	2.339e+04	2.302	0.02380	*
wohnflaeche	1.134e+03	1.272e+02	8.909	9.03e-14	***
I(schlafzimmer > 4)TRUE	1.049e+05	2.233e+04	4.699	1.01e-05	***
grundflaeche	2.019e+01	6.253e+00	3.229	0.00177	**

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 53990 on 84 degrees of freedom

Multiple R-squared: 0.7333, Adjusted R-squared: 0.7237

F-statistic: 76.97 on 3 and 84 DF, p-value: < 2.2e-16

Call:

```
lm(formula = preis ~ wohnflaeche + I(schlafzimmer > 4) + grundflaeche,  
    data = hauspreise)
```

Ganz oben steht der Funktionsaufruf ("Call") der `lm()` Funktion:

- 1 formula ist unsere Modellformel
- 2 data ist der Name unseres Datensatzes

Call:

```
lm(formula = preis ~ wohnflaeche + I(schlafzimmer > 4) + grundflaeche,  
    data = hauspreise)
```

Ganz oben steht der Funktionsaufruf (“Call”) der `lm()` Funktion:

- 1 formula ist unsere Modellformel
- 2 data ist der Name unseres Datensatzes

Die Modellformel übersetzen wir so:

- Allgemeine Formel:  $y_i = \beta_0 + \beta_1 x_{i,1} + \beta_2 x_{i,2} + \beta_3 x_{i,3} + u_i, i = 1, \dots, n$
- R Formel: `preis ~ wohnflaeche + I(schlafzimmer > 4) + grundflaeche`
- Übersetzt:

$$\text{preis}_i = \beta_0 + \beta_1 \text{wohnflaeche}_i + \beta_2 \underbrace{1\{\text{schlafzimmer} > 4\}}_{\text{Indikator-Variable}} + \beta_3 \text{grundflaeche} + u_i$$



Residuals:

Min	1Q	Median	3Q	Max
-149356	-27653	-3891	24175	202625

Als nächstes kommt eine Zusammenfassung der Residuen.

Was sind nochmal Residuen?

Für alle Beobachtungen  $i = 1, \dots, n$  ist das Residuum  $\hat{u}_i$  die Differenz aus dem beobachteten Preis  $\text{preis}_i$  und dem durch das Modell erklärten Preis  $\widehat{\text{preis}}_i$ , also:

$$\begin{aligned}\hat{u}_i &= \text{preis}_i - \widehat{\text{preis}}_i \\ &= \text{preis}_i - (\hat{\beta}_0 + \hat{\beta}_1 \text{wohnflaeche}_i + \hat{\beta}_2 1\{\text{schlafzimmer} > 4\} + \hat{\beta}_3 \text{grundflaeche}).\end{aligned}$$

Residuals:

Min	1Q	Median	3Q	Max
-149356	-27653	-3891	24175	202625

Die konkreten Residuenwerte für unser geschätztes Modell bekommen wir so:

```
residuals <- model$residuals  
head(residuals, n = 5)
```

1	2	3	4	5
-22070.79	78966.08	-17285.44	-19952.80	42983.91

Residuals:

Min	1Q	Median	3Q	Max
-149356	-27653	-3891	24175	202625

Die konkreten Residuenwerte für unser geschätztes Modell bekommen wir so:

```
residuals <- model$residuals  
head(residuals, n = 5)
```

1	2	3	4	5
-22070.79	78966.08	-17285.44	-19952.80	42983.91

```
summary(residuals)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-149356	-27653	-3891	0	24175	202625

Residuals:

Min	1Q	Median	3Q	Max
-149356	-27653	-3891	24175	202625

Was für Werte wünschen wir uns hier eigentlich?

Residuals:

Min	1Q	Median	3Q	Max
-149356	-27653	-3891	24175	202625

Was für Werte wünschen wir uns hier eigentlich?

Wir möchten, dass die Residuen symmetrisch um die geschätzte Regressionslinie streuen, also sollte:

- $|\text{Min}| \approx \text{Max}$
- $|\text{1Q}| \approx \text{3Q}$
- $\text{Median} \approx 0$

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	5.384e+04	2.339e+04	2.302	0.02380	*
wohnflaeche	1.134e+03	1.272e+02	8.909	9.03e-14	***
I(schlafzimmer > 4)TRUE	1.049e+05	2.233e+04	4.699	1.01e-05	***
grundflaeche	2.019e+01	6.253e+00	3.229	0.00177	**
---					

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

In dieser Tabelle stehen Informationen über die Kleinste-Quadrate-Schätzwerte.

Die Zeilennamen sind:

- (Intercept), also  $\beta_0$
- wohnflaeche, also der zur Variable wohnflaeche gehörige Koeffizient  $\beta_1$
- I(schlafzimmer > 4)TRUE, also  $\beta_2$
- grundflaeche, also  $\beta_3$

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	5.384e+04	2.339e+04	2.302	0.02380	*
wohnflaeche	1.134e+03	1.272e+02	8.909	9.03e-14	***
I(schlafzimmer > 4)TRUE	1.049e+05	2.233e+04	4.699	1.01e-05	***
grundflaeche	2.019e+01	6.253e+00	3.229	0.00177	**
---					

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

In Spalte Estimate stehen die Schätzwerte, also:

- $\hat{\beta}_0 = 5.384e+04 = 5.384 \cdot 10^4 = 53840$
- $\hat{\beta}_1 = 1.134e+03 = 1134$
- $\hat{\beta}_2 = 1.049e+05 = 10490$
- $\hat{\beta}_3 = 2.019e+01 = 20.19$

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	5.384e+04	2.339e+04	2.302	0.02380	*
wohnflaeche	1.134e+03	1.272e+02	8.909	9.03e-14	***
I(schlafzimmer > 4)TRUE	1.049e+05	2.233e+04	4.699	1.01e-05	***
grundflaeche	2.019e+01	6.253e+00	3.229	0.00177	**

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

In Spalte Estimate stehen die Schätzwerte, also:

- $\hat{\beta}_0 = 5.384e+04 = 5.384 \cdot 10^4 = 53840$
- $\hat{\beta}_1 = 1.134e+03 = 1134$
- $\hat{\beta}_2 = 1.049e+05 = 10490$
- $\hat{\beta}_3 = 2.019e+01 = 20.19$

Damit können wir jetzt interpretieren, dass ein zusätzlicher Quadratmeter Wohnfläche *ceteris paribus* (alles andere bleibt gleich) den Verkaufspreis um 1134 Dollar erhöht.



Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	5.384e+04	2.339e+04	2.302	0.02380	*
wohnflaeche	1.134e+03	1.272e+02	8.909	9.03e-14	***
I(schlafzimmer > 4)TRUE	1.049e+05	2.233e+04	4.699	1.01e-05	***
grundflaeche	2.019e+01	6.253e+00	3.229	0.00177	**

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

In Spalte Std. Error stehen die Standardfehler der geschätzten Koeffizienten (für deren Berechnung wir übrigens die Homoskedastie der Fehler  $u_i$  annehmen), also:

- $se(\hat{\beta}_0) = 2.339e+04 = 23390$
- $se(\hat{\beta}_1) = 1.272e+02 = 127.2$
- $se(\hat{\beta}_2) = 2.233e+04 = 22330$
- $se(\hat{\beta}_3) = 6.253e+00 = 6.253$

Hier gilt, dass ein kleinerer Standardfehler für einen präziseren Schätzwert steht.

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	5.384e+04	2.339e+04	2.302	0.02380	*
wohnflaeche	1.134e+03	1.272e+02	8.909	9.03e-14	***
I(schlafzimmer > 4)TRUE	1.049e+05	2.233e+04	4.699	1.01e-05	***
grundflaeche	2.019e+01	6.253e+00	3.229	0.00177	**

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

In Spalte t value stehen die Teststatistiken mit denen wir testen, ob ein Regressor einen signifikanten Einfluss auf die zu erklärende Variable (den Preis) hat:

$$H_0: \beta_k = 0$$

$$H_1: \beta_k \neq 0$$

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	5.384e+04	2.339e+04	2.302	0.02380	*
wohnflaeche	1.134e+03	1.272e+02	8.909	9.03e-14	***
I(schlafzimmer > 4)TRUE	1.049e+05	2.233e+04	4.699	1.01e-05	***
grundflaeche	2.019e+01	6.253e+00	3.229	0.00177	**

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

In Spalte t value stehen die Teststatistiken mit denen wir testen, ob ein Regressor einen signifikanten Einfluss auf die zu erklärende Variable (den Preis) hat:

$$H_0: \beta_k = 0$$

$$H_1: \beta_k \neq 0$$

Für jeden Koeffizienten  $k = 0, \dots, 3$  wird dafür folgendes berechnet:

$$\text{t value} = t_k = \frac{\hat{\beta}_k}{\text{se}(\hat{\beta}_k)} = \frac{\text{Estimate}}{\text{Std. Error}}$$

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	5.384e+04	2.339e+04	2.302	0.02380	*
wohnflaeche	1.134e+03	1.272e+02	8.909	9.03e-14	***
I(schlafzimmer > 4)TRUE	1.049e+05	2.233e+04	4.699	1.01e-05	***
grundflaeche	2.019e+01	6.253e+00	3.229	0.00177	**
---					
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1					

Unter der Annahme, dass die Fehler normalverteilt sind, gilt:

$$t_k = \frac{\hat{\beta}_k}{se(\hat{\beta}_k)} \sim t(n - K - 1)$$

- $t(n - K - 1)$  ist die  $t$ -Verteilung mit  $n - K - 1$  Freiheitsgraden
- $n = 88$  ist der Stichprobenumfang
- $K = 3$  ist die Anzahl an Regressoren (ohne Intercept!)

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	5.384e+04	2.339e+04	2.302	0.02380	*
wohnflaeche	1.134e+03	1.272e+02	8.909	9.03e-14	***
I(schlafzimmer > 4)TRUE	1.049e+05	2.233e+04	4.699	1.01e-05	***
grundflaeche	2.019e+01	6.253e+00	3.229	0.00177	**

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

In der Spalte  $\text{Pr}(>|t|)$  stehen die “p-values”. Das sind die Wahrscheinlichkeiten, mit denen wir unter der  $t(n - K - 1)$ -Verteilung einen betragsmäßig größeren Wert als  $t_k$  beobachten.


Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	5.384e+04	2.339e+04	2.302	0.02380	*
wohnflaeche	1.134e+03	1.272e+02	8.909	9.03e-14	***
I(schlafzimmer > 4)TRUE	1.049e+05	2.233e+04	4.699	1.01e-05	***
grundflaeche	2.019e+01	6.253e+00	3.229	0.00177	**

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

In der Spalte  $\text{Pr}(>|t|)$  stehen die “p-values”. Das sind die Wahrscheinlichkeiten, mit denen wir unter der  $t(n - K - 1)$ -Verteilung einen betragsmäßig größeren Wert als  $t_k$  beobachten. Also zum Beispiel für den Intercept:



Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	5.384e+04	2.339e+04	2.302	0.02380	*
wohnflaeche	1.134e+03	1.272e+02	8.909	9.03e-14	***
I(schlafzimmer > 4)TRUE	1.049e+05	2.233e+04	4.699	1.01e-05	***
grundflaeche	2.019e+01	6.253e+00	3.229	0.00177	**
---					

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Wie trifft man nochmal die Testentscheidung?

Wenn  $p\text{-value} < \alpha$ , verwirfe  $H_0 : \beta_k = 0$ .

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	5.384e+04	2.339e+04	2.302	0.02380	*
wohnflaeche	1.134e+03	1.272e+02	8.909	9.03e-14	***
I(schlafzimmer > 4)TRUE	1.049e+05	2.233e+04	4.699	1.01e-05	***
grundflaeche	2.019e+01	6.253e+00	3.229	0.00177	**
---					

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Wie trifft man nochmal die Testentscheidung?

Wenn  $p\text{-value} < \alpha$ , verwirfe  $H_0 : \beta_k = 0$ .

Also ist der Intercept signifikant zu  $\alpha = 5\%$ , denn  $0.02380 < 0.05$ .



Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	5.384e+04	2.339e+04	2.302	0.02380	*
wohnflaeche	1.134e+03	1.272e+02	8.909	9.03e-14	***
I(schlafzimmer > 4)TRUE	1.049e+05	2.233e+04	4.699	1.01e-05	***
grundflaeche	2.019e+01	6.253e+00	3.229	0.00177	**

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Wie trifft man nochmal die Testentscheidung?

Wenn  $p\text{-value} < \alpha$ , verwirfe  $H_0 : \beta_k = 0$ .

Also ist der Intercept signifikant zu  $\alpha = 5\%$ , denn  $0.02380 < 0.05$ .

Die Sterne in der rechten Spalte bieten einen schnellen Überblick:

- Koeffizienten mit  $p\text{-value} < 10\%$  bekommen einen .
- $p\text{-value} < 5\%$  gibt \*,  $p\text{-value} < 1\%$  gibt \*\*,  $p\text{-value} < 0.1\%$  gibt \*\*\*

Residual standard error: 53990 on 84 degrees of freedom  
Multiple R-squared: 0.7333, Adjusted R-squared: 0.7237  
F-statistic: 76.97 on 3 and 84 DF, p-value: < 2.2e-16

Am Ende stehen noch drei Zeilen mit viel Information:

- 1 ein Schätzwert für die Standardabweichung  $\sigma$  der Fehler  $u_i$
- 2 die Gütekriterien  $R^2$  und adjustiertes  $R^2$
- 3 das Ergebnis des “Overall- $F$ -Test”

Residual standard error: 53990 on 84 degrees of freedom

Der Schätzwert für die Standardabweichung  $\sigma$  der Fehler ist

$$\hat{\sigma} = \sqrt{SSR/(n - K - 1)}$$

Residual standard error: 53990 on 84 degrees of freedom

Der Schätzwert für die Standardabweichung  $\sigma$  der Fehler ist

$$\hat{\sigma} = \sqrt{SSR/(n - K - 1)}$$

wobei  $SSR$  (für “Sum of squared residuals”) die Summe der quadrierten Residuen ist:

$$SSR = \sum_{i=1}^n \hat{u}_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i^2)$$

Residual standard error: 53990 on 84 degrees of freedom

Der Schätzwert für die Standardabweichung  $\sigma$  der Fehler ist

$$\hat{\sigma} = \sqrt{SSR/(n - K - 1)}$$

wobei  $SSR$  (für “Sum of squared residuals”) die Summe der quadrierten Residuen ist:

$$SSR = \sum_{i=1}^n \hat{u}_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i^2)$$

```
sqrt(sum(model$residuals^2)/84)
```

```
[1] 53986.52
```

(im `summary()` Output wurde gerundet, daher der kleine Unterschied)

Residual standard error: 53990 on 84 degrees of freedom

Zur Erinnerung: Neben  $SSR$  gibt es auch noch

- $SST = \sum_{i=1}^n (y_i - \bar{y})^2$  (für “Sum of squares total”) und
- $SSE = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$  (für “Sum of squares explained”).

Residual standard error: 53990 on 84 degrees of freedom

Zur Erinnerung: Neben  $SSR$  gibt es auch noch

- $SST = \sum_{i=1}^n (y_i - \bar{y})^2$  (für “Sum of squares total”) und
- $SSE = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$  (für “Sum of squares explained”).

Es gilt  $SST = SSE + SSR$ , das heißt, die Gesamtvariabilität des Datensatzes ( $SST$ ) ist gleich der durch die Regression erklärten Variabilität ( $SSE$ ) plus der unerklärten Variabilität ( $SSR$ ).

Multiple R-squared: 0.7333, Adjusted R-squared: 0.7237

Multiple R-squared ist das  $R^2$  mit

$$R^2 = SSE/SST = 1 - SSR/SST,$$

das heißt die Größe  $R^2$  gibt den Anteil der durch das Modell erklärten Variabilität an der Gesamtvariabilität im Datensatz an (hier 73,33% - ganz gut!).



Multiple R-squared: 0.7333, Adjusted R-squared: 0.7237

Multiple R-squared ist das  $R^2$  mit

$$R^2 = SSE/SST = 1 - SSR/SST,$$

das heißt die Größe  $R^2$  gibt den Anteil der durch das Modell erklärten Variabilität an der Gesamtvariabilität im Datensatz an (hier 73,33% - ganz gut!).

Daneben steht das adjustierte  $R^2$ :

$$\bar{R}^2 = 1 - \frac{SSR/(n - K - 1)}{SST/(n - 1)}.$$

Was ist eigentlich der Unterschied?

Während  $R^2$  zwingend mit jedem hinzugefügten Regressor steigt, tut das  $\bar{R}^2$  nicht notwendigerweise. Also ist  $R^2$  nicht zur Modellselektion geeignet,  $\bar{R}^2$  aber schon.

F-statistic: 76.97 on 3 and 84 DF, p-value: < 2.2e-16

Die letzte Zeile ist das Ergebnis des “Overall- $F$ -Test” (Globaler  $F$ -Test). Er testet

$$H_0: \beta_1 = \beta_2 = \beta_3 = 0$$

$$H_1: \beta_1 \neq 0 \text{ oder } \beta_2 \neq 0 \text{ oder } \beta_3 \neq 0$$

F-statistic: 76.97 on 3 and 84 DF, p-value: < 2.2e-16

Die letzte Zeile ist das Ergebnis des “Overall- $F$ -Test” (Globaler  $F$ -Test). Er testet

$$H_0: \beta_1 = \beta_2 = \beta_3 = 0$$

$$H_1: \beta_1 \neq 0 \text{ oder } \beta_2 \neq 0 \text{ oder } \beta_3 \neq 0$$

Der Wert der Teststatistik wurde berechnet mit der Formel

$$\text{F-statistic} = F = \frac{R^2/K}{(1 - R^2)/(n - K - 1)}$$

```
r.squared <- summary(model)$r.squared  
(r.squared/3)/((1 - r.squared)/84)
```

```
[1] 76.97402
```

F-statistic: 76.97 on 3 and 84 DF, p-value: < 2.2e-16

Die letzte Zeile ist das Ergebnis des “Overall- $F$ -Test” (Globaler  $F$ -Test). Er testet

$$H_0: \beta_1 = \beta_2 = \beta_3 = 0$$

$$H_1: \beta_1 \neq 0 \text{ oder } \beta_2 \neq 0 \text{ oder } \beta_3 \neq 0$$

Der Wert der Teststatistik wurde berechnet mit der Formel

$$\text{F-statistic} = F = \frac{R^2/K}{(1 - R^2)/(n - K - 1)}$$

```
r.squared <- summary(model)$r.squared  
(r.squared/3)/((1 - r.squared)/84)
```

```
[1] 76.97402
```

Die Teststatistik ist  $F$ -verteilt zu  $K$  und  $n - K - 1$  Freiheitsgraden (DF). Außerdem ist der p-value angegeben. Natürlich gilt auch hier:  $H_0$  verwerfen, wenn  $\text{p-value} < \alpha$ .

Call:

```
lm(formula = preis ~ wohnflaeche + I(schlafzimmer > 4) + grundflaeche,  
    data = hauspreise)
```

Residuals:

Min	1Q	Median	3Q	Max
-149356	-27653	-3891	24175	202625

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	5.384e+04	2.339e+04	2.302	0.02380 *
wohnflaeche	1.134e+03	1.272e+02	8.909	9.03e-14 ***
I(schlafzimmer > 4)TRUE	1.049e+05		4.699	1.01e-05 ***
grundflaeche	2.019e+01	6.253e+00	3.229	0.00177
---				

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 53990 on 84 degrees of freedom

Multiple R-squared: 0.7333, Adjusted R-squared: 0.7237

F-statistic: 76.97 on and DF, p-value: < 2.2e-16

## Dein Selbsttest:

- 1 Was ist  $se(\hat{\beta}_2)$ ?
- 2 Wie viele Signifikanzsterne hat  $\hat{\beta}_3$ ?
- 3 Wie groß ist  $n$ ?
- 4 Wie groß ist  $SSE$ ?
- 5 Welche Freiheitsgrade hat die  $F$ -Statistik?